Detecção de Tumores Cerebrais em Imagens de Ressonância Magnética por *Transfer Learning* com Validação Cruzada por Grupos

Matheus Lemes Amaral
FGA0261 — Inteligência Artificial II
Universidade de Brasília (UnB)
Brasília, Brasil
Matrícula: 241031852

Eduardo Jesus Dal Pizzol
FGA0261 — Inteligência Artificial II
Universidade de Brasília (UnB)
Brasília, Brasil
Matrícula: 251008114

***Resumo*—Conjuntos públicos de ressonância magnética (RM) cerebral costumam ser pequenos e conter imagens repetidas. Este trabalho classifica fatias de RM em "com tumor" e "sem tumor" no conjunto público *Brain MRI Images for Brain Tumor Detection* (253 imagens), após remover 25 cópias idênticas e agrupar quase-duplicatas por *hash* perceptual. Uma ResNet-18 pré-treinada no ImageNet é comparada a uma CNN treinada do zero, e quatro configurações de treino são comparadas por validação cruzada estratificada por grupos (5 *folds* $\times$ 3 sementes). A ResNet-18 obteve AUC média de $0{,}917$ a $0{,}923$ nas três melhores configurações, e nenhuma diferença pareada em relação à configuração inicial se afastou de zero (melhor caso: $+0{,}005$, IC 95% $[-0{,}010;\ 0{,}021]$). No teste (34 imagens), a melhor configuração errou uma imagem (acurácia $0{,}971$, AUC $0{,}989$), contra AUC de $0{,}733$ da CNN sem pré-treino. Sem identificação de paciente nem validação externa, os resultados são exploratórios e não indicam uso clínico.**

***Palavras-chave*—aprendizado profundo, *transfer learning*, ressonância magnética, tumor cerebral, validação cruzada.**

I. Introdução

A ressonância magnética é o principal exame de imagem para detectar e acompanhar tumores cerebrais, e sua leitura depende da experiência do examinador. Redes neurais convolucionais (CNNs) já foram aplicadas à classificação de tumores em RM [1], [2] e podem apoiar a triagem ao sinalizar exames suspeitos para revisão, sem substituir o diagnóstico.

Os conjuntos públicos mais acessíveis, porém, são pequenos e podem conter a mesma imagem mais de uma vez; nesse caso, a divisão aleatória coloca cópias de um exame no treino e no teste, e o desempenho relatado fica inflado por vazamento de dados [3], problema identificado em mais da metade dos estudos de CNN em RM revisados por Wen *et al.* [4]. Além disso, comparações entre configurações costumam relatar uma única divisão, sem incerteza.

Este trabalho compara uma ResNet-18 [5] pré-treinada a uma CNN treinada do zero e avalia quatro configurações de treino com deduplicação, divisão por grupos de quase-duplicatas e teste usado uma única vez, ao final. São investigadas três questões de pesquisa:

- **QP1:** o *transfer learning* do ImageNet melhora a classificação em relação a uma CNN treinada do zero com tão poucos dados?
- **QP2:** ajustes de agendamento da taxa de aprendizado, *weight decay* e congelamento inicial alteram a discriminação quando avaliados por validação cruzada por grupos?
- **QP3:** um limiar escolhido na validação para garantir alta sensibilidade compensa em relação ao limiar fixo de 0,5?

A Seção II apresenta a fundamentação; a III, a metodologia; a IV, os resultados; a V, a discussão e as ameaças à validade; e a VI conclui.

II. Fundamentação e Trabalhos Relacionados

No *transfer learning*, uma rede pré-treinada em uma base grande, como o ImageNet [6], é reaproveitada em outra tarefa. As primeiras camadas aprendem filtros genéricos, como bordas e texturas, e as últimas, padrões específicos da tarefa original [7]; por isso, o *fine-tuning* costuma funcionar com poucas imagens médicas. A ResNet [5] introduziu conexões residuais, em que cada bloco aprende uma correção $F(x)$ somada à entrada x, o que permite treinar redes profundas sem degradação; a ResNet-18, com a cabeça de uma saída usada aqui, tem 11,2M de parâmetros.

Com classes desbalanceadas, a acurácia favorece a classe majoritária; por isso, relatam-se também sensibilidade, especificidade, F1 e a AUC ROC, que independe do limiar. Quando há várias imagens do mesmo exame, a validação precisa manter cada grupo inteiro em uma única partição, como faz a validação cruzada estratificada por grupos [8].

Swati *et al.* [1] ajustaram uma CNN pré-treinada bloco a bloco para classificar glioma, meningioma e tumor hipofisário em RM ponderada em T1 com contraste, com acurácia média de 94,8% em validação cruzada de 5 *folds*, e Deepak e Ameer [2] usaram atributos de uma GoogLeNet pré-treinada no mesmo problema de três classes. Para segmentação, o BRATS [9] estabeleceu um *benchmark* multimodal de gliomas. Diferentemente desses trabalhos, este estudo usa um conjunto binário pequeno e de fonte única e concentra-se no protocolo: deduplicação, divisão por grupos e comparação pareada de configurações com incerteza.

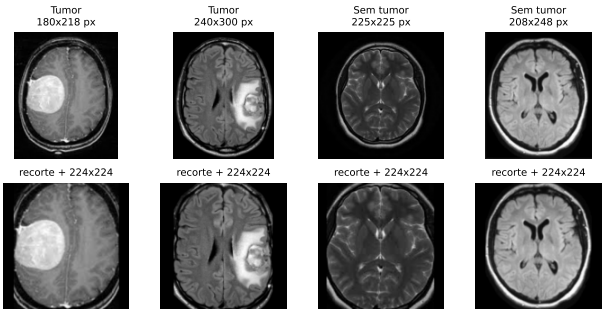


Figura 1. Exemplos do conjunto original (acima), com resoluções variadas, e o resultado do recorte do crânio e da padronização em 224×224 (abaixo).

Tabela I
PROTOCOLO EXPERIMENTAL.

Aspecto	Configuração
Dados	*Brain MRI Images for Brain Tumor Detection* [10]; 253 imagens (155 tumor, 98 sem tumor)
Amostra	228 imagens únicas (25 cópias removidas); 216 grupos de quase-duplicatas (*dHash* 8×8)
Rótulos	Binário por imagem: tumor / sem tumor
Divisão	70/15/15 por grupo, estratificada por classe (semente 42): 160/34/34 imagens
Entrada	Recorte do crânio, *padding* quadrado, 224×224, normalização ImageNet
Aumento (treino)	Recorte aleatório (escala 0,85–1), espelhamento horizontal, rotação $\pm 15°$, brilho e contraste $\pm 20\%$
Modelos	ResNet-18 (11,2M; pesos ImageNet) e CNN simples (1,2M; do zero); *dropout* 0,3 + 1 *logit*
Perda	Entropia cruzada binária com peso positivo $n_{\text{sem}}/n_{\text{tumor}}$
Otimização	AdamW [11]; taxa 10^{-4} (10^{-3} na CNN simples); lote 32; cosseno [12]; precisão mista bf16
Treino	Até 60 ou 25 épocas; parada antecipada pela perda de validação (paciência 15); GPU A100 80 GB
Seleção	Validação cruzada por grupos, 5 *folds* $\times$ 3 sementes; maior AUC média (critério fixado antes)
Limiar	0,5 fixo; alternativa: maior limiar com sensibilidade $\geq$ 0,95 na validação interna
Incerteza	*Bootstrap* sobre as imagens de teste (2.000 repetições), IC 95% [13]

III. METODOLOGIA

A. Dados e rótulos

Utilizou-se o conjunto público *Brain MRI Images for Brain Tumor Detection* [10], com 253 fatias axiais de RM cerebral em duas pastas: 155 com tumor e 98 sem tumor. As imagens são heterogêneas: há 184 resoluções diferentes e quatro modos de cor (RGB, tons de cinza, RGBA e paleta), e não há metadados de paciente, sequência ou equipamento. A unidade de análise é a imagem, e a tarefa é binária. A inspeção dos arquivos revelou 25 cópias idênticas byte a byte de outras imagens e outros pares quase idênticos.

B. Pré-processamento e divisão

Cada imagem foi convertida para tons de cinza e as 25 cópias foram descartadas, restando 228 imagens. Para capturar quase-duplicatas, calculou-se um *hash* de diferença (*dHash*) de 64 bits: a imagem é reduzida a 9×8 pixels e cada bit indica se um pixel é mais claro que o vizinho da direita. Imagens com o mesmo *hash* foram unidas em 216 grupos, e um grupo nunca é dividido entre partições.

Tabela II
CONFIGURAÇÕES DE TREINO COMPARADAS (RESNET-18).

Configuração	Épocas	*Warmup*	*W. decay*	Só cabeça	LR cabeça
`baseline`	60	0	10^{-4}	0	10^{-4}
`schedule`	25	2	10^{-4}	0	10^{-4}
`schedule_wd`	25	2	$5 \cdot 10^{-2}$	0	10^{-4}
`sched._wd_freeze`	25	2	$5 \cdot 10^{-2}$	3	10^{-3}

O crânio foi isolado por filtro gaussiano 5×5, limiarização em 45, erosão e dilatação, e a imagem foi recortada na caixa do maior contorno externo. O recorte recebeu bordas pretas até ficar quadrado, o que preserva a proporção, e foi redimensionado para 224×224 pixels (Fig. 1). Grupos inteiros de cada classe foram então sorteados para treino, validação e teste na proporção 70/15/15 (Tabela I). O aumento de dados foi aplicado só no treino, sem espelhamento vertical, que inverteria a anatomia.

C. Modelos e treinamento

As duas redes têm uma saída única (*logit*), com a sigmoide aplicada dentro da perda. A ResNet-18 foi carregada do torchvision com pesos do ImageNet, e a última camada foi substituída por *dropout* e uma camada linear; toda a rede foi ajustada. A CNN simples tem quatro blocos de duas convoluções 3×3 com *batch normalization*, ReLU e *max pooling* (32 a 256 canais), seguidos de *pooling* médio global.

Partindo do primeiro experimento (`baseline`), três configurações acrescentam, cada uma, uma mudança à anterior (Tabela II). No `baseline`, o cosseno foi dimensionado para 60 épocas, mas a parada antecipada encerrou o treino na época 23, e a taxa de aprendizado ainda estava em 96% do valor inicial na melhor época; 10^{-4} é um *weight decay* fraco para o AdamW; e treinar a rede inteira desde o início deixa a cabeça aleatória propagar gradientes ruidosos para as camadas pré-treinadas.

D. Avaliação e inferência

As configurações foram comparadas por validação cruzada usando só as 194 imagens de treino e validação. Para cada semente (42, 43 e 44), as imagens foram divididas em 5 *folds* com `StratifiedGroupKFold` [8], que preserva a proporção das classes e mantém cada grupo em um único *fold*. Em cada *fold*, o modelo treina em quatro partes, com validação interna por grupos (15%) para a parada antecipada e o limiar, e é avaliado na quinta (36 a 41 imagens). São 15 execuções por configuração, com as mesmas sementes e *folds* para todas; a comparação com o `baseline` é pareada, com IC 95% pela distribuição t sobre as 15 diferenças.

A configuração vencedora e o `baseline` foram retreinados na divisão original e avaliados uma única vez no teste, com IC 95% por *bootstrap*. Hiperparâmetros, épocas e limiares foram

Tabela III
TESTE (34 IMAGENS): RESNET-18 PRÉ-TREINADA VS. CNN DO ZERO [IC 95% POR *bootstrap*].

Métrica	Trivial[a]	ResNet-18	CNN simples
Acurácia	0,618	**0,912** [0,79; 1,00]	0,765 [0,62; 0,91]
Precisão	0,618	**0,909** [0,76; 1,00]	0,760 [0,58; 0,92]
Sensibilidade	1,000	**0,952** [0,84; 1,00]	0,905 [0,76; 1,00]
Especificidade	0,000	**0,846** [0,63; 1,00]	0,538 [0,25; 0,80]
F1	0,764	**0,930** [0,84; 1,00]	0,826 [0,68; 0,93]
AUC	0,500	**0,971** [0,90; 1,00]	0,733 [0,51; 0,92]
VN/FP/FN/VP	0/13/0/21	11/2/1/20	7/6/2/19

[a]Prever todas as imagens como tumor. Prevalência no teste: 62%.

Tabela IV
VALIDAÇÃO CRUZADA POR GRUPOS: MÉDIA ± DESVIO (15 EXECUÇÕES, LIMIAR 0,5) E DIFERENÇA PAREADA DE AUC EM RELAÇÃO AO `baseline`.

Config.	AUC	F1	Especif.	ΔAUC [IC 95%]
`baseline`	$0{,}917 \pm 0{,}054$	$0{,}870 \pm 0{,}039$	$0{,}796 \pm 0{,}118$	–
`schedule`	$0{,}919 \pm 0{,}051$	$0{,}882 \pm 0{,}037$	$0{,}779 \pm 0{,}120$	$+0{,}002$ [$-0{,}017$; $0{,}020$]
`sched._wd`	$\mathbf{0{,}923} \pm 0{,}051$	$0{,}883 \pm 0{,}040$	$0{,}787 \pm 0{,}126$	$+0{,}005$ [$-0{,}010$; $0{,}021$]
`s._wd_frz.`	$0{,}906 \pm 0{,}091$	$0{,}876 \pm 0{,}061$	$0{,}756 \pm 0{,}122$	$-0{,}011$ [$-0{,}050$; $0{,}028$]

definidos sem acesso ao teste. Código, divisão e predições estão em https://github.com/1emes/MRI-segmentation.

IV. RESULTADOS

A. Transfer learning versus treino do zero

No primeiro experimento (divisão única, configuração `baseline`), a ResNet-18 pré-treinada superou a CNN treinada do zero em todas as métricas de teste (Tabela III). A CNN simples classificou quase metade das imagens saudáveis como tumor (especificidade 0,538) e obteve AUC de 0,733, com intervalo que vai de 0,51 a 0,92; a ResNet-18 errou três das 34 imagens.

B. Configurações de treino na validação cruzada

A Tabela IV e a Fig. 2 resumem as 15 execuções de cada configuração. As três primeiras ficaram entre 0,917 e 0,923 de AUC, e nenhuma diferença pareada em relação ao `baseline` teve intervalo que excluísse zero: a melhor, `schedule_wd`, ganhou $+0{,}005$ (IC $[-0{,}010;\ 0{,}021]$), com 9 vitórias, 1 empate e 5 derrotas. Congelar o *backbone* nas três primeiras épocas reduziu a AUC em $0{,}011$ e quase dobrou o desvio entre *folds* ($0{,}091$ contra $0{,}054$). Cada execução levou de 10 a 27 s, e as 60 execuções, cerca de 7 min com as quatro configurações em paralelo; uma segunda rodada completa reproduziu todos os números.

C. Limiar de decisão

O limiar escolhido na validação interna para sensibilidade $\geq 0{,}95$ não compensou. No `baseline`, elevou a sensibilidade média de 0,870 para 0,912, mas reduziu a especificidade de 0,796 para 0,670, com desvio de 0,262 (Fig. 2). Com 23 a 25 imagens em cada validação interna, o limiar do `baseline` oscilou de 0,02 a 0,70 entre *folds*, e o limiar fixo de 0,5 foi mantido.

Tabela V
TESTE (34 IMAGENS): `baseline` VS. `schedule_wd` [IC 95% POR *bootstrap*].

Métrica	`baseline`	`schedule_wd`
Acurácia	0,912 [0,79; 1,00]	**0,971** [0,91; 1,00]
Precisão	0,909 [0,76; 1,00]	**1,000** [1,00; 1,00]
Sensibilidade	0,952 [0,84; 1,00]	0,952 [0,84; 1,00]
Especificidade	0,846 [0,63; 1,00]	**1,000** [1,00; 1,00]
F1	0,930 [0,84; 1,00]	**0,976** [0,91; 1,00]
AUC	0,971 [0,90; 1,00]	**0,989** [0,95; 1,00]
VN/FP/FN/VP	11/2/1/20	13/0/1/20
Melhor época / total	8 / 23	11 / 25

D. Avaliação final no conjunto de teste

Retreinada na divisão original, a configuração `schedule_wd` atingiu a menor perda de validação na época 11 de 25 e errou uma das 34 imagens de teste (Tabela V e Fig. 3), um tumor que o `baseline` também não detectou; a diferença entre as duas são duas imagens saudáveis que o `baseline` marcou como tumor. Os limiares escolhidos na validação (0,646 e 0,422) não alteraram nenhuma predição de teste.

V. DISCUSSÃO E AMEAÇAS À VALIDADE

Para a QP1, o *transfer learning* foi o fator determinante: a CNN treinada do zero ficou 0,24 abaixo em AUC e quase não separou as imagens saudáveis, algo esperado com 160 imagens de treino.

Para a QP2, não há evidência de que os ajustes de treino alterem a discriminação: todas as diferenças pareadas têm intervalo que inclui zero, e vitórias e derrotas se dividem quase igualmente. A vantagem de `schedule_wd` no teste (0,971 contra 0,912 de acurácia) se resume a duas imagens e está dentro dos intervalos de confiança.

Para a QP3, o limiar ajustado troca pouca sensibilidade por muita especificidade, e de forma instável; uma política de limiar exigiria uma validação maior. Resistem às limitações a vantagem do pré-treino e a equivalência entre as configurações; a estimativa mais confiável do desempenho esperado é a da validação cruzada (AUC próxima de 0,92 e acurácia de 0,85), e não a do teste.

Validade interna e estatística. As 15 execuções de cada configuração compartilham imagens de treino, então os ICs pareados são aproximados e tendem a ser estreitos demais. O teste tem 34 imagens, o que explica intervalos de até 0,4 de largura. O *dHash* agrupa apenas quase-duplicatas com *hash* idêntico; cópias recortadas ou com contraste diferente podem ter escapado.

Validade de construção. Sem identificação de paciente, não há garantia de que fatias do mesmo paciente fiquem na mesma partição, o que pode inflar todas as métricas. Os rótulos são os das pastas do conjunto, sem revisão por especialista, e não há tipo de tumor nem localização. As classes podem diferir em resolução, sequência e formato do arquivo, o que abre atalhos não relacionados ao tumor.

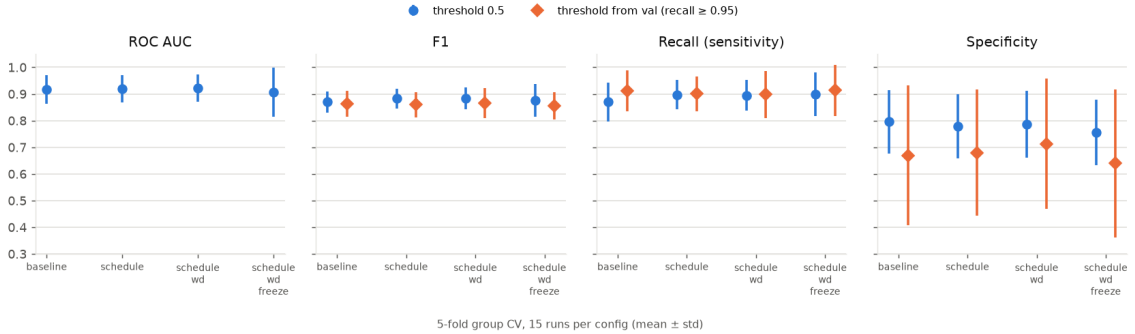


Figura 2. Validação cruzada por grupos (média ± desvio de 15 execuções por configuração) com limiar fixo de 0,5 (círculos) e limiar escolhido na validação interna para sensibilidade $\geq 0{,}95$ (losangos).

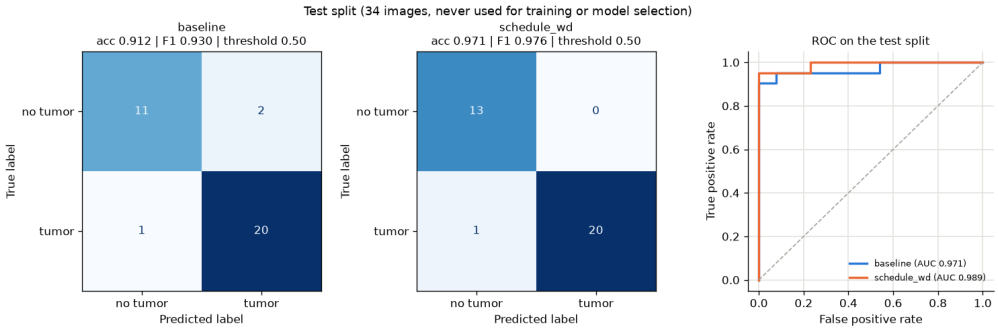


Figura 3. Matrizes de confusão e curvas ROC no conjunto de teste, nunca usado em treino, seleção de modelo ou escolha de limiar.

Validade externa. Os dados vêm de uma única coleção, sem metadados de aquisição nem validação externa. Os resultados não indicam uso clínico; no máximo, apoio à triagem após validação em dados independentes.

VI. Conclusão

Este trabalho comparou uma ResNet-18 pré-treinada e uma CNN treinada do zero na detecção de tumores cerebrais em RM, com deduplicação, divisão por grupos de quase-duplicatas e comparação pareada de quatro configurações de treino por validação cruzada. O pré-treino no ImageNet foi decisivo (AUC de teste de 0,971 contra 0,733), enquanto os ajustes de agendamento, regularização e congelamento ficaram dentro do ruído. O repositório traz ainda ferramentas de segmentação por K-means [14] e edição manual de máscaras, com três pares imagem/máscara criados. Trabalhos futuros devem usar conjuntos maiores e identificados por paciente, validação externa, calibração das probabilidades e máscaras suficientes para treinar uma rede de segmentação, como a U-Net [15].

Referências

[1] Z. N. K. Swati *et al.*, "Brain tumor classification for MR images using transfer learning and fine-tuning," *Comput. Med. Imaging Graph.*, vol. 75, pp. 34–46, 2019.

[2] S. Deepak and P. M. Ameer, "Brain tumor classification using deep CNN features via transfer learning," *Comput. Biol. Med.*, vol. 111, p. 103345, 2019.

[3] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023.

[4] J. Wen *et al.*, "Convolutional neural networks for classification of Alzheimer's disease: Overview and reproducible evaluation," *Med. Image Anal.*, vol. 63, p. 101694, 2020.

[5] K. He, X. Zhang, S. Ren and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE CVPR*, 2016, pp. 770–778.

[6] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li and L. Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *Proc. IEEE CVPR*, 2009, pp. 248–255.

[7] J. Yosinski, J. Clune, Y. Bengio and H. Lipson, "How transferable are features in deep neural networks?" in *Advances in NeurIPS*, vol. 27, 2014, pp. 3320–3328.

[8] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[9] B. H. Menze *et al.*, "The multimodal brain tumor image segmentation benchmark (BRATS)," *IEEE Trans. Med. Imag.*, vol. 34, no. 10, pp. 1993–2024, 2015.

[10] N. Chakrabarty, "Brain MRI images for brain tumor detection," Kaggle, 2019. [Online]. Available: https://www.kaggle.com/datasets/navoneel/brain-mri-images-for-brain-tumor-detection

[11] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Proc. ICLR*, 2019.

[12] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *Proc. ICLR*, 2017.

[13] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[14] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proc. 5th Berkeley Symp. Math. Statist. Probab.*, 1967, pp. 281–297.

[15] O. Ronneberger, P. Fischer and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Proc. MICCAI*, 2015, pp. 234–241.