Detecção de Tumores Cerebrais em Imagens de Ressonância Magnética com Transferência de Aprendizado e Validação Cruzada por Grupos

Matheus Lemes Amaral
Universidade de Brasília (UnB)
Brasília, DF, Brasil
Matrícula: 241031852

***Resumo*—Este trabalho apresenta um *pipeline* completo para classificar fatias de ressonância magnética (RM) cerebral em "com tumor" e "sem tumor" a partir de um conjunto público pequeno (253 imagens). O pré-processamento remove 25 cópias idênticas, agrupa quase-duplicatas por *hash* perceptual para que nenhuma imagem repetida cruze as partições, recorta o crânio e padroniza as imagens em 224×224. Uma ResNet-18 pré-treinada na ImageNet é comparada a uma CNN treinada do zero e quatro configurações de treino são avaliadas com validação cruzada estratificada por grupos (5 *folds* $\times$ 3 sementes, 60 treinos em GPU A100). A ResNet-18 atinge AUC ROC média de $0{,}92 \pm 0{,}05$ e acurácia de $0{,}85 \pm 0{,}05$ na validação cruzada; as variações de agendamento da taxa de aprendizado e de *weight decay* ficam dentro do ruído (ΔAUC $\leq 0{,}005$). No conjunto de teste isolado (34 imagens), a melhor configuração erra uma única imagem (acurácia $0{,}971$, AUC $0{,}989$), enquanto a CNN sem pré-treino fica em acurácia $0{,}765$ e AUC $0{,}733$.**

***Index Terms*—ressonância magnética, tumor cerebral, aprendizado profundo, transferência de aprendizado, ResNet-18, validação cruzada.**

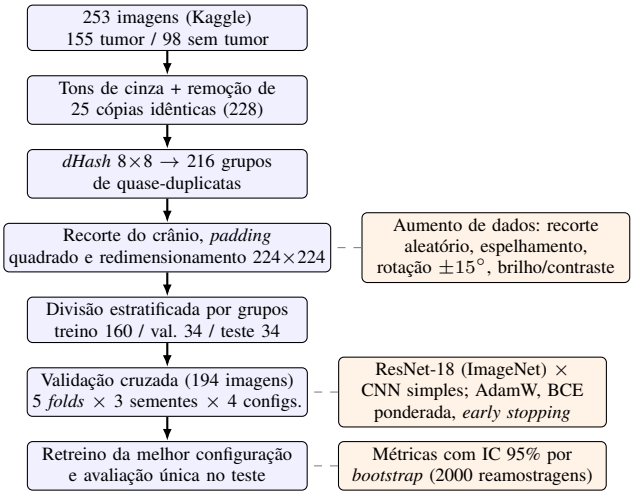


Figura 1. Visão geral do *pipeline* de pré-processamento, treino e avaliação.

I. Introdução

A ressonância magnética é o principal exame de imagem para a detecção de tumores cerebrais, e a triagem automática de exames pode reduzir o tempo até o diagnóstico. Redes neurais convolucionais (CNNs) são o método padrão para esse tipo de classificação, mas os conjuntos públicos de RM costumam ser pequenos, heterogêneos e conter imagens repetidas. Nesse cenário, dois riscos dominam: o modelo decorar um conjunto tão pequeno e a métrica de teste ser inflada por vazamento de dados [1], quando cópias do mesmo exame caem no treino e no teste.

Este trabalho descreve o repositório *MRI-segmentation*, que implementa um classificador binário (tumor / sem tumor) com três cuidados principais: (i) deduplicação e particionamento por grupos de quase-duplicatas; (ii) transferência de aprendizado a partir da ImageNet [2] com uma ResNet-18 [3]; e (iii) comparação de configurações de treino por validação cruzada estratificada por grupos, com o conjunto de teste usado uma única vez, ao final. O repositório traz ainda ferramentas de segmentação por K-means para a criação de máscaras.

II. Conjunto de Dados

Foi usado o conjunto público *Brain MRI Images for Brain Tumor Detection* [4], com 253 imagens (155 com tumor e 98 sem tumor). As imagens são heterogêneas: há 184 resoluções diferentes e quatro modos de cor (RGB, tons de cinza, RGBA e paleta). A inspeção dos arquivos revelou 25 cópias idênticas byte a byte de outras imagens e alguns pares quase idênticos. Uma divisão aleatória simples colocaria cópias do mesmo exame no treino e no teste e superestimaria o desempenho.

III. Metodologia

A Fig. 1 resume o *pipeline*, executado em uma GPU NVIDIA A100-SXM4-80GB do Google Colab (PyTorch 2.11, CUDA 13.0) por meio de um script que empacota o código e os dados, roda os experimentos e baixa os resultados.

A. Pré-processamento

Cada imagem é convertida para tons de cinza e as 25 cópias idênticas são descartadas (253 $\rightarrow$ 228 imagens). Para capturar quase-duplicatas, calcula-se um *hash* de diferença (*dHash*) de 8×8 bits: a imagem é reduzida a 9×8 pixels e cada bit indica se um pixel é mais claro que o vizinho da direita. Imagens com o mesmo *hash* são unidas por uma estrutura *union-find*, resultando em 216 grupos; um grupo nunca é dividido entre partições.

Em seguida, o crânio é isolado: aplica-se um filtro gaussiano 5×5, limiarização em 45, erosão e dilatação, e a imagem é

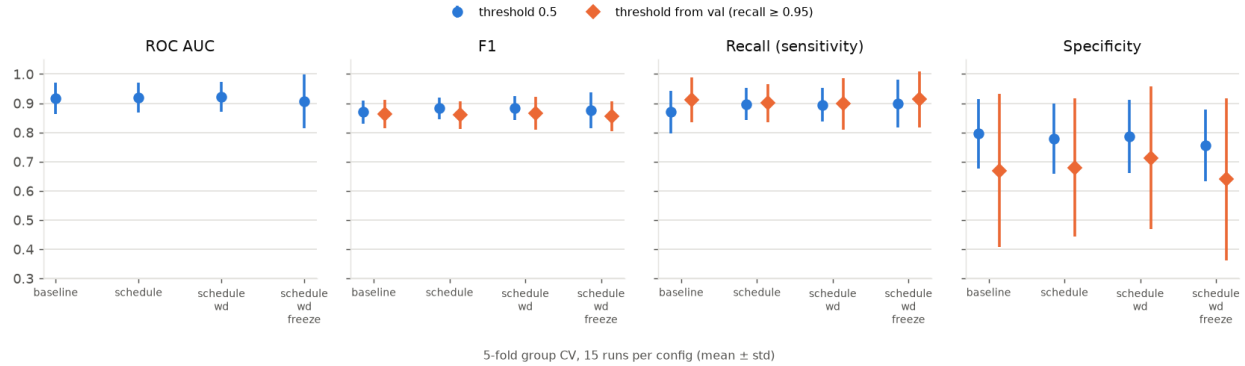


Figura 2. Validação cruzada (média ± desvio padrão de 15 execuções por configuração) com limiar fixo de 0,5 (círculos) e limiar escolhido na validação interna para *recall* $\geq 0{,}95$ (losangos). O limiar ajustado ganha pouco em *recall* e perde muito, e de forma instável, em especificidade.

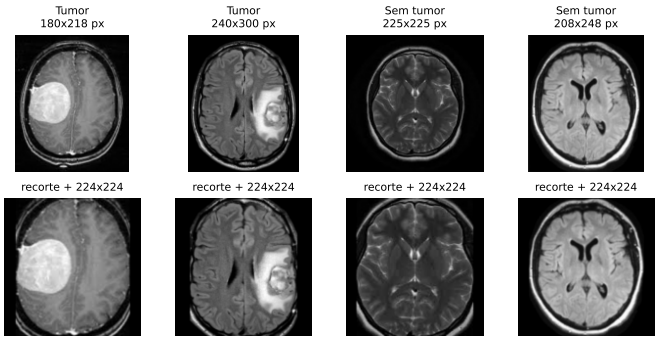


Figura 3. Exemplos do conjunto original (acima), com resoluções variadas, e o resultado do recorte do crânio e da padronização em 224×224 (abaixo).

Tabela I
PARTIÇÕES APÓS DEDUPLICAÇÃO (DIVISÃO POR GRUPOS)

Partição	Sem tumor	Tumor	Total
Treino	61	99	160
Validação	13	21	34
Teste	13	21	34
Total	87	141	228

recortada na caixa delimitadora do maior contorno externo (com retorno à imagem inteira se o contorno for menor que 20% da largura ou altura). O recorte recebe bordas pretas até ficar quadrado, preservando a proporção, e é redimensionado para 224×224 (Fig. 3). Por fim, grupos inteiros de cada classe são sorteados (semente 42) para as partições de treino, validação e teste na proporção 70/15/15 (Tabela I).

B. Modelos

Foram comparadas duas arquiteturas com saída de um único *logit*:

- **ResNet-18** [3] pré-treinada na ImageNet, com a camada final substituída por *dropout* (0,3) e uma camada linear (11,2 M parâmetros);
- **CNN simples**, treinada do zero: quatro blocos de duas convoluções 3×3 com *batch normalization*, ReLU e *max pooling* (32 a 256 canais), seguidos de *pooling* médio global e camada linear (1,2 M parâmetros).

Tabela II
CONFIGURAÇÕES DE TREINO COMPARADAS

Configuração	Épocas	*Warmup*	*W. decay*	Só cabeça	LR cabeça
`baseline`	60	0	10^{-4}	0	10^{-4}
`schedule`	25	2	10^{-4}	0	10^{-4}
`schedule_wd`	25	2	$5 \cdot 10^{-2}$	0	10^{-4}
`schedule_wd_freeze`	25	2	$5 \cdot 10^{-2}$	3	10^{-3}

C. Treinamento

Todas as execuções usam aumento de dados (recorte aleatório redimensionado com escala de 0,85 a 1, espelhamento horizontal, rotação de até 15° e variação de brilho e contraste de 20%), normalização pelas estatísticas da ImageNet, perda *BCEWithLogits* com `pos_weight` $= n_{\text{sem}}/n_{\text{tumor}}$ para compensar o desbalanceamento, otimizador AdamW [5], lote de 32, taxa de aprendizado 10^{-4} e precisão mista bf16. Guarda-se o modelo com a menor perda de validação, com *early stopping* após 15 épocas sem melhora.

Partindo do primeiro experimento (`baseline`), três configurações acrescentam, cada uma, uma mudança à anterior (Tabela II). A motivação veio da análise do `baseline`: o decaimento cosseno [6] foi dimensionado para 60 épocas, mas o *early stopping* encerrou o treino na época 23, de modo que a taxa de aprendizado ainda estava em 96% do valor inicial na melhor época; além disso, 10^{-4} é um *weight decay* fraco para o AdamW, e treinar a rede inteira desde o início permite que a cabeça aleatória propague gradientes ruidosos para as camadas pré-treinadas.

D. Protocolo de avaliação

As configurações são comparadas por validação cruzada usando apenas as 194 imagens de treino e validação; o teste permanece intocado. Para cada semente (42, 43 e 44), as imagens são divididas em 5 *folds* com `StratifiedGroupKFold` [7], preservando a proporção das classes e mantendo cada grupo de quase-duplicatas em

Tabela III
TESTE (34 IMAGENS): RESNET-18 PRÉ-TREINADA VS. CNN DO ZERO (IC 95%)

Métrica	ResNet-18	CNN simples
Acurácia	**0,912** (0,79–1,00)	0,765 (0,62–0,91)
Precisão	**0,909** (0,76–1,00)	0,760 (0,58–0,92)
Recall	**0,952** (0,84–1,00)	0,905 (0,76–1,00)
Especificidade	**0,846** (0,63–1,00)	0,538 (0,25–0,80)
F1	**0,930** (0,84–1,00)	0,826 (0,68–0,93)
AUC ROC	**0,971** (0,90–1,00)	0,733 (0,51–0,92)
VN / FP / FN / VP	11 / 2 / 1 / 20	7 / 6 / 2 / 19

um único *fold*. Em cada *fold*, o modelo treina em quatro partes, com uma validação interna por grupos (15%) para o *early stopping*, e é avaliado na quinta. São 15 execuções por configuração e 60 no total, com as mesmas sementes e *folds* para todas, o que permite comparações pareadas. O critério de escolha foi fixado antes dos experimentos: maior AUC ROC média.

Também foi testado um limiar de decisão escolhido na validação interna (o maior que mantém *recall* $\geq 0{,}95$), além do limiar fixo de 0,5. A configuração vencedora e o `baseline` são então retreinados na divisão original e avaliados uma única vez no teste, com intervalos de confiança de 95% obtidos por 2000 reamostragens *bootstrap* [8]. As métricas são acurácia, precisão, *recall* (sensibilidade), especificidade, F1 e AUC ROC.

IV. RESULTADOS

A. ResNet-18 versus CNN simples

No primeiro experimento (divisão única, configuração `baseline`), a transferência de aprendizado foi decisiva (Tabela III). A CNN treinada do zero classificou quase metade das imagens saudáveis como tumor (especificidade 0,538) e obteve AUC de apenas 0,733, enquanto a ResNet-18 pré-treinada errou três das 34 imagens de teste.

B. Validação cruzada das configurações

A Tabela IV e a Fig. 2 mostram a média e o desvio padrão das 15 execuções de cada configuração. A melhor, `schedule_wd`, atinge AUC de $0{,}923 \pm 0{,}051$, apenas $+0{,}005$ acima do `baseline`, com 9 vitórias, 1 empate e 5 derrotas na comparação pareada. Ajustar o cosseno à duração real do treino e aumentar o *weight decay* são escolhas sensatas, mas mudam pouco o modelo. Congelar o *backbone* nas três primeiras épocas piorou levemente a AUC ($-0{,}011$) e quase dobrou a dispersão entre *folds*. Cada execução levou de 14 a 17 s; as 60 execuções levaram cerca de 7 min com as quatro configurações em paralelo na mesma GPU, e uma segunda rodada completa reproduziu todos os números.

O limiar escolhido na validação interna não compensou: no `baseline`, elevou o *recall* de 0,870 para 0,912, mas reduziu a especificidade de 0,796 para $0{,}670 \pm 0{,}262$. Com cerca de 23 imagens em cada validação interna, o limiar oscila muito entre *folds*, e por isso o limiar fixo de 0,5 foi mantido. As curvas

Tabela IV
VALIDAÇÃO CRUZADA POR GRUPOS (5 *folds* × 3 SEMENTES, LIMIAR 0,5)

Config.	AUC ROC	Acurácia	F1	Especif.
`baseline`	$0{,}917 \pm 0{,}054$	$0{,}840 \pm 0{,}045$	$0{,}870 \pm 0{,}039$	$0{,}796 \pm 0{,}118$
`schedule`	$0{,}919 \pm 0{,}051$	$0{,}852 \pm 0{,}048$	$0{,}882 \pm 0{,}037$	$0{,}779 \pm 0{,}120$
`sched._wd`	$\mathbf{0{,}923} \pm 0{,}051$	$0{,}853 \pm 0{,}051$	$0{,}883 \pm 0{,}040$	$0{,}787 \pm 0{,}126$
`sched._wd_fr.`	$0{,}906 \pm 0{,}091$	$0{,}844 \pm 0{,}070$	$0{,}876 \pm 0{,}061$	$0{,}756 \pm 0{,}122$

Tabela V
TESTE (34 IMAGENS): `BASELINE` VS. `SCHEDULE_WD` (IC 95%)

Métrica	`baseline`	`schedule_wd`
Acurácia	0,912 (0,79–1,00)	**0,971** (0,91–1,00)
Precisão	0,909 (0,76–1,00)	**1,000** (1,00–1,00)
Recall	0,952 (0,84–1,00)	0,952 (0,84–1,00)
Especificidade	0,846 (0,63–1,00)	**1,000** (1,00–1,00)
F1	0,930 (0,84–1,00)	**0,976** (0,91–1,00)
AUC ROC	0,971 (0,90–1,00)	**0,989** (0,95–1,00)
VN / FP / FN / VP	11 / 2 / 1 / 20	13 / 0 / 1 / 20
Melhor época / total	8 / 23	11 / 25

ROC agregadas das predições fora do *fold* (Fig. 5) confirmam a ordem das configurações, todas entre 0,909 e 0,918.

C. Avaliação final no conjunto de teste

Retreinada na divisão original, a configuração `schedule_wd` atingiu a menor perda de validação na época 11 de 25 e errou apenas uma das 34 imagens de teste (Tabela V e Fig. 4), um tumor que o `baseline` também não detectou. A diferença entre as duas são as duas imagens saudáveis que o `baseline` marcou como tumor. Os limiares escolhidos na validação (0,646 e 0,422) não alteraram nenhuma predição de teste. A Fig. 6 mostra as curvas de treino: a perda de treino tende a zero enquanto a de validação estabiliza a partir da época 11, sinal de sobreajuste contido pela seleção do melhor *checkpoint*.

V. DISCUSSÃO

O resultado no teste (0,971 de acurácia) é superior ao da validação cruzada (0,85), mas a diferença entre `baseline` e `schedule_wd` no teste são apenas duas imagens e está dentro dos intervalos de confiança. A estimativa mais confiável do desempenho esperado é a da validação cruzada, que média 15 avaliações de cerca de 39 imagens cada: AUC próxima de 0,92 e acurácia próxima de 0,85 para qualquer uma das três primeiras configurações. A deduplicação foi essencial para essa honestidade: sem ela, 25 pares de imagens idênticas e outras quase-duplicatas poderiam estar simultaneamente no treino e no teste.

As principais limitações são o tamanho do conjunto (228 imagens únicas), a ausência de identificação de pacientes, que impede garantir que fatias do mesmo paciente fiquem na mesma partição, e a mistura de sequências e protocolos de aquisição sem metadados. A parte de segmentação do repositório ainda é preliminar: o `kmeans.py` agrupa os pixels por cor com K-means [9] e gera uma máscara por agrupamento, e o `eraser.py` oferece um pincel interativo para

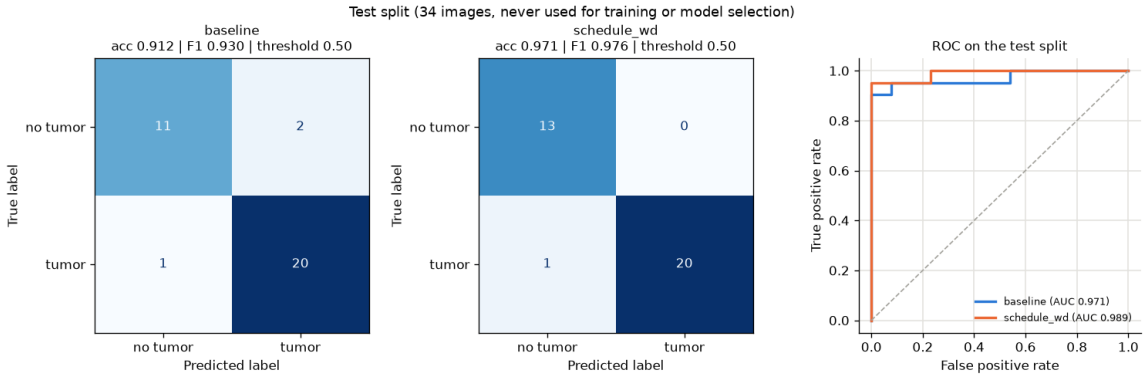


Figura 4. Matrizes de confusão e curvas ROC no conjunto de teste, nunca usado em treino, seleção de modelo ou escolha de limiar.

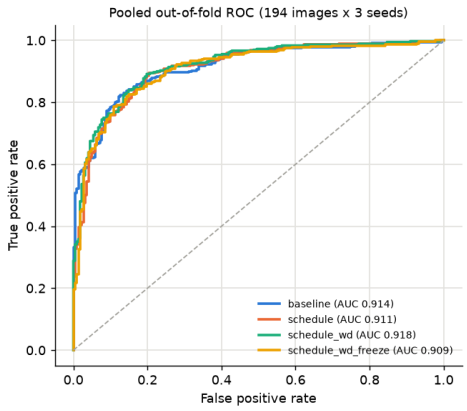


Figura 5. Curvas ROC agregadas das predições fora do *fold* (194 imagens $\times$ 3 sementes).

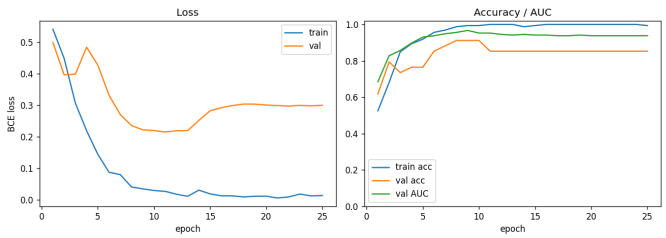


Figura 6. Curvas de perda, acurácia e AUC do treino final da configuração `schedule_wd`.

limpar as máscaras; com essas ferramentas foram criados três pares imagem/máscara, insuficientes para treinar um modelo de segmentação.

VI. Conclusão

Foi desenvolvido um *pipeline* reprodutível de detecção de tumores cerebrais em RM que trata explicitamente duplicatas e vazamento de dados e compara configurações por validação cruzada por grupos antes de tocar o conjunto de teste. A transferência de aprendizado com a ResNet-18 foi o fator determinante (AUC de teste de 0,971 contra 0,733 da CNN treinada do zero), enquanto os ajustes de agendamento e regularização ficaram dentro do ruído estatístico. Como trabalhos futuros, propõem-se ampliar a base com conjuntos maiores e identificados por paciente, calibrar as probabilidades do modelo e produzir máscaras suficientes para treinar uma rede de segmentação, como a U-Net.

Referências

[1] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023.

[2] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *Proc. IEEE CVPR*, 2009, pp. 248–255.

[3] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE CVPR*, 2016, pp. 770–778.

[4] N. Chakrabarty, "Brain MRI images for brain tumor detection," Kaggle, 2019. [Online]. Available: https://www.kaggle.com/datasets/navoneel/brain-mri-images-for-brain-tumor-detection

[5] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Proc. ICLR*, 2019.

[6] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *Proc. ICLR*, 2017.

[7] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[8] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York, NY, USA: Chapman & Hall, 1993.

[9] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proc. 5th Berkeley Symp. Math. Statist. Probab.*, 1967, pp. 281–297.