Detecção de Tumores Cerebrais em Imagens de Ressonância Magnética por *Transfer Learning* com Validação Cruzada por Grupos

Matheus Lemes Amaral
FGA0261 — Inteligência Artificial II
Universidade de Brasília (UnB)
Brasília, Brasil
Matrícula: 241031852

Eduardo Jesus Dal Pizzol
FGA0261 — Inteligência Artificial II
Universidade de Brasília (UnB)
Brasília, Brasil
Matrícula: 251008114

***Resumo*—Este trabalho classifica imagens de ressonância magnética (RM) cerebral em "com tumor" e "sem tumor" no conjunto *Brain MRI Images for Brain Tumor Detection* (253 imagens), com deduplicação e divisão por grupos de quase-duplicatas. Para isolar o efeito do pré-treino, uma ResNet-18 com pesos do ImageNet é comparada à mesma rede com inicialização aleatória e mesmo treinamento, e quatro configurações de treino são comparadas por validação cruzada estratificada por grupos (5 *folds* $\times$ 3 sementes). O pré-treino elevou a AUC média de $0{,}744$ para $0{,}917$ (diferença pareada de $0{,}173$, IC 95% corrigido $[0{,}047;\ 0{,}299]$), e a rede pré-treinada venceu as 15 execuções. Entre as configurações, não foi detectado ganho consistente de AUC. No teste (34 imagens), a ResNet-18 pré-treinada errou 3 imagens e a aleatória, 9 (McNemar exato, $p = 0{,}031$). Sem identificação de paciente nem validação externa, os resultados são exploratórios e não indicam uso clínico.**

***Palavras-chave*—aprendizado profundo, *transfer learning*, ressonância magnética, tumor cerebral, validação cruzada.**

I. Introdução

A ressonância magnética é o principal exame de imagem para detectar e acompanhar tumores cerebrais, e sua leitura depende da experiência do examinador. Redes neurais convolucionais (CNNs) já foram aplicadas à classificação de tumores em RM [1], [2] e podem apoiar a triagem ao sinalizar exames suspeitos para revisão, sem substituir o diagnóstico.

Os conjuntos públicos mais acessíveis, porém, são pequenos e podem conter a mesma imagem mais de uma vez; nesse caso, a divisão aleatória coloca cópias de um exame no treino e no teste, e o desempenho relatado fica inflado por vazamento de dados [3]. Em uma revisão de estudos de CNN para classificação da doença de Alzheimer por RM, Wen *et al.* [4] apontaram que mais da metade pode ter sofrido vazamento de dados.

Este trabalho avalia uma ResNet-18 [5] com e sem pré-treino e quatro configurações de treino, com deduplicação, divisão por grupos de quase-duplicatas e teste reservado para a avaliação final. São investigadas três questões de pesquisa:

- **QP1:** o pré-treino no ImageNet melhora a ResNet-18 em relação à mesma rede com inicialização aleatória e o mesmo treinamento?
- **QP2:** ajustes de agendamento da taxa de aprendizado, *weight decay* e congelamento inicial produzem ganho consistente de AUC na validação cruzada por grupos?
- **QP3:** um limiar escolhido para atingir sensibilidade empírica $\geq 0{,}95$ na validação compensa em relação ao limiar fixo de 0,5?

A Seção II apresenta a fundamentação; a III, a metodologia; a IV, os resultados; a V, a discussão e as ameaças à validade; e a VI conclui.

II. Fundamentação e Trabalhos Relacionados

No *transfer learning*, uma rede pré-treinada em uma base grande, como o ImageNet [6], é reaproveitada em outra tarefa. As primeiras camadas aprendem filtros genéricos, como bordas e texturas [7], o que favorece o *fine-tuning* com poucas imagens médicas. A ResNet [5] introduziu conexões residuais, em que cada bloco aprende uma correção $F(x)$ somada à entrada x, o que permite treinar redes profundas sem degradação; a ResNet-18, com a cabeça de uma saída usada aqui, tem 11,2M de parâmetros.

Com classes desbalanceadas, a acurácia favorece a classe majoritária; por isso, relatam-se também sensibilidade, especificidade, F1 e a AUC ROC, que independe do limiar. Quando há várias imagens do mesmo exame, a validação precisa manter cada grupo inteiro em uma única partição, como faz a validação cruzada estratificada por grupos [8]. Como os conjuntos de treino de *folds* diferentes se sobrepõem, as execuções não são independentes, e o teste t convencional subestima a variância das diferenças; Nadeau e Bengio [9] propuseram uma correção para esse caso.

Swati *et al.* [1] e Deepak e Ameer [2] usaram CNNs pré-treinadas para classificar glioma, meningioma e tumor hipofisário em RM ponderada em T1 com contraste. Diferentemente desses trabalhos, este estudo usa um conjunto binário pequeno e de fonte única e concentra-se no protocolo: deduplicação, divisão por grupos, controle do pré-treino e comparação pareada com incerteza.

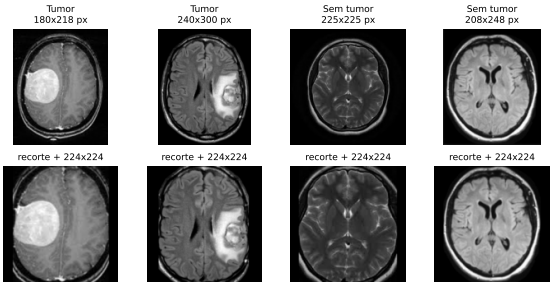


Figura 1. Exemplos do conjunto original (acima), com resoluções variadas, e o resultado do recorte da região delimitada pelo maior contorno e da padronização em 224×224 (abaixo).

Tabela I
PROTOCOLO EXPERIMENTAL.

Aspecto	Configuração
Dados	*Brain MRI Images for Brain Tumor Detection* [10]; 253 imagens (155 tumor, 98 sem tumor)
Amostra	228 imagens únicas (141 tumor, 87 sem tumor); 216 grupos de quase-duplicatas (*dHash* 8×8)
Divisão	70/15/15 por grupo, estratificada por classe (semente 42): 160/34/34 imagens
Entrada	Recorte do maior contorno, *padding* quadrado, 224×224; tons de cinza replicados em 3 canais; normalização ImageNet
Aumento (treino)	Recorte aleatório (escala 0,85–1), espelhamento horizontal, rotação $\pm 15°$, brilho e contraste $\pm 20\%$
Modelos	ResNet-18 (11,2M) com pesos ImageNet ou aleatórios; CNN simples (1,2M); *dropout* 0,3 + 1 *logit*
Perda	Entropia cruzada binária com peso positivo $n_{\text{sem}}/n_{\text{tumor}}$ do subconjunto de treino de cada execução
Otimização	AdamW [11]; taxa 10^{-4} (10^{-3} na CNN simples); lote 32; cosseno [12]; bf16
Treino	Até 60 ou 25 épocas; parada antecipada pela perda de validação (paciência 15); GPU A100 80 GB

III. METODOLOGIA

A. Dados e rótulos

Utilizou-se o conjunto público *Brain MRI Images for Brain Tumor Detection* [10], com 253 imagens de RM cerebral em duas pastas: 155 com tumor e 98 sem tumor. As imagens são heterogêneas: há 184 resoluções diferentes e quatro modos de cor (RGB, tons de cinza, RGBA e paleta), e não há metadados de paciente, sequência, orientação ou equipamento. A unidade de análise é a imagem, e a tarefa é binária.

B. Pré-processamento e divisão

Cada imagem foi convertida para tons de cinza e as 25 cópias idênticas byte a byte foram descartadas, restando 228 imagens (141 com tumor e 87 sem tumor). Para capturar quase-duplicatas, calculou-se um *hash* de diferença (*dHash*) de 64 bits: a imagem é reduzida a 9×8 pixels e cada bit indica se um pixel é mais claro que o vizinho da direita. Imagens com o mesmo *hash* foram unidas em 216 grupos, e um grupo nunca é dividido entre partições.

Aplicaram-se filtro gaussiano 5×5, limiarização em 45, erosão e dilatação, e a imagem foi recortada na caixa delimitadora do maior contorno externo, que em geral corresponde à cabeça. O recorte recebeu bordas pretas até ficar quadrado, o que preserva a proporção, e foi redimensionado para 224×224 pixels (Fig. 1). Grupos inteiros de cada classe foram então sorteados para treino, validação e teste na proporção 70/15/15 (Tabela I). Na entrada das redes, a imagem em tons de cinza é replicada nos três canais e normalizada pelas estatísticas do ImageNet. O aumento de dados foi aplicado só no treino, sem espelhamento vertical, que inverteria a anatomia.

Tabela II
CONFIGURAÇÕES DE TREINO DA RESNET-18 (*Warm.*: ÉPOCAS DE *warmup*; WD: *weight decay*; CONG.: ÉPOCAS SÓ DA CABEÇA; LR CAB.: TAXA DA CABEÇA).

Configuração	Pesos	Épocas	*Warm.*	WD	Cong.	LR cab.
`baseline`	ImageNet	60	0	10^{-4}	0	10^{-4}
`baseline_scratch`	aleat.	60	0	10^{-4}	0	10^{-4}
`schedule`	ImageNet	25	2	10^{-4}	0	10^{-4}
`schedule_wd`	ImageNet	25	2	$5 \cdot 10^{-2}$	0	10^{-4}
`schedule_wd_freeze`	ImageNet	25	2	$5 \cdot 10^{-2}$	3	10^{-3}

C. Modelos e treinamento

As redes têm uma saída única (*logit*), com a sigmoide aplicada dentro da perda, e toda a rede é ajustada. A ResNet-18 do torchvision teve a última camada substituída por *dropout* e uma camada linear e foi treinada em duas versões, que diferem apenas na inicialização: com pesos do ImageNet (`baseline`) e aleatória (`baseline_scratch`), com arquitetura, hiperparâmetros, sementes e *folds* idênticos. A CNN simples, com quatro blocos de duas convoluções 3×3, *batch normalization*, ReLU e *max pooling* (32 a 256 canais), é uma referência adicional, com outra arquitetura e taxa de aprendizado.

A partir do `baseline`, três configurações alteram a anterior (Tabela II): `schedule` encurta o horizonte do cosseno de 60 para 25 épocas e acrescenta *warmup*; `schedule_wd` aumenta o *weight decay*; e `schedule_wd_freeze` treina só a cabeça nas três primeiras épocas, com taxa dez vezes maior. A motivação foi que, no `baseline`, o treino foi interrompido na época 23, mas o melhor modelo foi obtido na época 8, quando a taxa de aprendizado ainda correspondia a aproximadamente 97% do valor inicial. Como algumas transições mudam mais de um fator, as diferenças não são atribuídas a um fator isolado.

D. Avaliação e inferência

As configurações foram comparadas por validação cruzada usando só as 194 imagens de treino e validação. Para cada semente (42, 43 e 44), as imagens foram divididas em 5 *folds* com `StratifiedGroupKFold` [8], que preserva a proporção das classes e mantém cada grupo em um único *fold*. Em cada *fold*, o modelo treina em quatro partes, com validação interna por grupos (15%, 23 a 25 imagens) para a parada antecipada e o limiar, e é avaliado na quinta (36 a 41 imagens). As 15 execuções usam as mesmas sementes e *folds* em todas as configurações; as diferenças pareadas de AUC em relação ao `baseline` recebem o IC 95% do teste t

Tabela III
VALIDAÇÃO CRUZADA POR GRUPOS: MÉDIA ± DESVIO DE 15 EXECUÇÕES E DIFERENÇA PAREADA DE AUC EM RELAÇÃO AO `baseline`, COM IC 95% DO TESTE t CORRIGIDO (EXPLORATÓRIO) E VITÓRIAS/EMPATES/DERROTAS.

		Limiar 0,5		Limiar da validação		
Configuração	AUC	Sensibilidade	Especificidade	Sensibilidade	Especificidade	ΔAUC [IC 95%]; V/E/D
`baseline`	$0{,}917 \pm 0{,}054$	$0{,}870 \pm 0{,}073$	$0{,}796 \pm 0{,}118$	$0{,}912 \pm 0{,}077$	$0{,}670 \pm 0{,}262$	–
`baseline_scratch`	$0{,}744 \pm 0{,}082$	$0{,}702 \pm 0{,}101$	$0{,}633 \pm 0{,}162$	$0{,}902 \pm 0{,}087$	$0{,}364 \pm 0{,}222$	$-0{,}173$ [$-0{,}299$; $-0{,}047$]; 0/0/15
`schedule`	$0{,}919 \pm 0{,}051$	$0{,}897 \pm 0{,}054$	$0{,}779 \pm 0{,}120$	$0{,}901 \pm 0{,}065$	$0{,}680 \pm 0{,}238$	$+0{,}002$ [$-0{,}039$; $0{,}042$]; 8/1/6
`schedule_wd`	$0{,}923 \pm 0{,}051$	$0{,}895 \pm 0{,}058$	$0{,}787 \pm 0{,}126$	$0{,}899 \pm 0{,}089$	$0{,}712 \pm 0{,}244$	$+0{,}005$ [$-0{,}028$; $0{,}039$]; 9/1/5
`schedule_wd_freeze`	$0{,}906 \pm 0{,}091$	$0{,}899 \pm 0{,}082$	$0{,}756 \pm 0{,}122$	$0{,}913 \pm 0{,}096$	$0{,}639 \pm 0{,}277$	$-0{,}011$ [$-0{,}097$; $0{,}075$]; 8/0/7

Tabela IV
TESTE (34 IMAGENS: 21 COM TUMOR, 13 SEM TUMOR). PROPORÇÕES COM IC 95% DE WILSON; AUC COM IC 95% POR *bootstrap*.

Métrica	Trivial[a]	`baseline` (ImageNet)	`baseline_scratch` (aleatória)	CNN simples	`schedule_wd` (ImageNet)
Acurácia	0,618	0,912 [0,77; 0,97]	0,735 [0,57; 0,85]	0,765 [0,60; 0,88]	0,971 [0,85; 0,99]
Precisão	0,618	0,909 [0,72; 0,97]	0,750 [0,55; 0,88]	0,760 [0,57; 0,89]	1,000 [0,84; 1,00]
Sensibilidade	1,000	0,952 [0,77; 0,99]	0,857 [0,65; 0,95]	0,905 [0,71; 0,97]	0,952 [0,77; 0,99]
Especificidade	0,000	0,846 [0,58; 0,96]	0,538 [0,29; 0,77]	0,538 [0,29; 0,77]	1,000 [0,77; 1,00]
F1	0,764	0,930	0,800	0,826	0,976
AUC	0,500	0,971 [0,90; 1,00]	0,766 [0,56; 0,94]	0,733 [0,51; 0,92]	0,989 [0,95; 1,00]
VN / FP / FN / VP	0 / 13 / 0 / 21	11 / 2 / 1 / 20	7 / 6 / 3 / 18	7 / 6 / 2 / 19	13 / 0 / 1 / 20

[a]Prever todas as imagens como tumor (prevalência no teste: 62%).

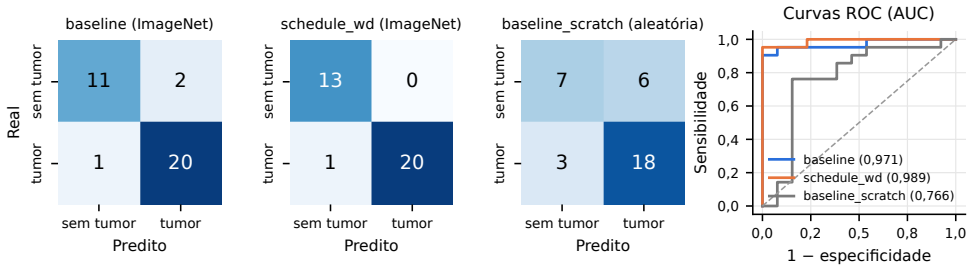


Figura 2. Matrizes de confusão e curvas ROC no conjunto de teste, nunca usado em treino, seleção de modelo ou escolha de limiar.

corrigido de Nadeau e Bengio [9], tratado como exploratório: $\bar{d} \pm t_{0{,}975;\,14}\, s\sqrt{1/15 + n_2/n_1}$, com média $\bar{d}$ e desvio s das 15 diferenças e $n_2/n_1 = 38{,}8/155{,}2 = 0{,}25$, razão entre as médias de imagens avaliadas e de ajuste (treino e validação interna) por *fold*.

O `baseline`, a configuração vencedora e o controle foram retreinados na divisão original e avaliados uma única vez no teste. As proporções recebem IC 95% de Wilson [13], que permanece informativo quando não há erros de um tipo, e a AUC, IC por *bootstrap* (2.000 reamostragens) [14]; os pares de modelos são comparados pelo teste exato de McNemar sobre as imagens em que discordam. O teste contém 34 imagens distribuídas em 32 grupos de *hash*; esses grupos não permitem determinar a dependência entre imagens do mesmo paciente. Hiperparâmetros, épocas, limiares e a configuração foram escolhidos sem acesso ao teste, mas ele foi consultado em três etapas: experimento inicial (ResNet-18 pré-treinada e CNN simples), `baseline` e configuração vencedora e, por último, controle aleatório, acrescentado com os resultados anteriores já conhecidos; as comparações no teste são, portanto, exploratórias. Código, divisão e predições estão em https://github.com/1emes/MRI-segmentation.

IV. RESULTADOS

A. *Efeito do pré-treino (QP1)*

Com arquitetura e treinamento idênticos, a inicialização aleatória reduziu a AUC média na validação cruzada de 0,917 para 0,744 (Tabela III): a diferença pareada foi de $-0{,}173$, com IC 95% corrigido $[-0{,}299;\ -0{,}047]$, e o `baseline` venceu as 15 execuções. A especificidade caiu de 0,796 para 0,633. No teste (Tabela IV), o `baseline` errou 3 das 34 imagens e o `baseline_scratch`, 9; nas 6 imagens em que discordaram, só o `baseline` acertou (McNemar exato, $p = 0{,}031$). O controle ficou no patamar da CNN simples, que também treina do zero com outra arquitetura: AUCs de 0,766 e 0,733, respectivamente, sem diferença detectada nas proporções de erro (McNemar exato, $p = 1{,}0$), o que não demonstra equivalência.

B. *Configurações de treino (QP2)*

As três configurações pré-treinadas alternativas ficaram entre 0,906 e 0,923 de AUC média, e nenhuma diferença pareada

em relação ao `baseline` teve intervalo que excluísse zero; os intervalos, porém, comportam diferenças de até cerca de 0,04 em ambos os sentidos, e de até 0,1 na configuração com congelamento. A configuração `schedule_wd` teve a maior média ($+0{,}005$; IC $[-0{,}028;\ 0{,}039]$; 9 vitórias, 1 empate e 5 derrotas) e foi a escolhida pelo critério fixado. A configuração com congelamento inicial e maior taxa de aprendizado da cabeça apresentou AUC média inferior ($-0{,}011$) e o maior desvio entre *folds* ($0{,}091$).

C. Limiar de decisão (QP3)

No `baseline`, o limiar escolhido na validação interna elevou a sensibilidade média de 0,870 para 0,912, mas reduziu a especificidade de 0,796 para 0,670, com desvio de 0,262 (Tabela III). Com 23 a 25 imagens em cada validação interna, esse limiar variou de 0,02 a 0,70 entre *folds*, e o limiar fixo de 0,5 foi mantido.

D. Avaliação final no conjunto de teste

Retreinada na divisão original, a configuração `schedule_wd` errou uma das 34 imagens de teste, um tumor que o `baseline` também não detectou (Tabela IV e Fig. 2). As predições das duas diferiram em duas imagens rotuladas como sem tumor, ambas acertadas só por `schedule_wd`, o que não constitui evidência de diferença (McNemar exato, $p = 0{,}5$). Os limiares escolhidos na validação (0,646 e 0,422) não alteraram nenhuma predição de teste.

V. Discussão e Ameaças à Validade

Para a QP1, o pré-treino no ImageNet foi o fator que mais pesou no desempenho, no protocolo avaliado: com arquitetura, hiperparâmetros, sementes e *folds* idênticos, a rede pré-treinada superou a aleatória em todas as execuções da validação cruzada e no teste.

Para a QP2, não foi detectada diferença consistente de AUC entre as configurações pré-treinadas, considerando o tamanho da amostra e a incerteza das estimativas; isso não demonstra equivalência, pois os intervalos admitem diferenças relevantes em ambos os sentidos. No teste, a vantagem de `schedule_wd` sobre o `baseline` se resume a duas imagens.

Para a QP3, o limiar ajustado proporcionou pequeno ganho de sensibilidade, acompanhado de perda expressiva de especificidade e de elevada variabilidade entre *folds*; atingir sensibilidade $\geq 0{,}95$ em 23 a 25 imagens de validação não garante o mesmo desempenho em imagens novas. A validação cruzada (AUC próxima de 0,92) resume o desempenho em múltiplas partições, embora permaneça sujeita às limitações do conjunto e do agrupamento.

Validade interna e estatística. O IC corrigido de Nadeau e Bengio atenua, mas não resolve por completo, o efeito da dependência entre execuções, e por isso é tratado como exploratório. O controle aleatório usou os hiperparâmetros escolhidos para *fine-tuning* (taxa 10^{-4}, até 60 épocas); em 4 dos 15 *folds*, a melhor época ocorreu após a época 40, de modo que uma busca própria de hiperparâmetros poderia reduzir a diferença. O *dHash* agrupa apenas quase-duplicatas com *hash* idêntico.

Validade de construção. Sem identificação de paciente, não há garantia de que imagens do mesmo paciente fiquem na mesma partição, o que pode inflar todas as métricas. Os rótulos são os das pastas do conjunto, sem revisão por especialista, e não há tipo de tumor nem localização. As classes podem diferir em resolução, sequência e formato do arquivo, o que abre atalhos não relacionados ao tumor.

Validade externa. Os dados vêm de uma única coleção, sem metadados de aquisição nem validação externa. Os resultados não indicam uso clínico; no máximo, apoio à triagem após validação em dados independentes.

VI. Conclusão

Com deduplicação, divisão por grupos e comparação pareada por validação cruzada, este trabalho mostrou que, com arquitetura e treinamento idênticos, a ResNet-18 pré-treinada no ImageNet superou a mesma rede com inicialização aleatória (AUC média de 0,917 contra 0,744 na validação cruzada e 0,971 contra 0,766 no teste). Entre as quatro configurações da ResNet-18 pré-treinada, não foi detectado ganho consistente de AUC. Os resultados permanecem exploratórios devido ao tamanho reduzido da amostra, à ausência de identificação de pacientes e à falta de validação externa. Trabalhos futuros devem usar conjuntos maiores e identificados por paciente, validação externa e busca de hiperparâmetros para o treino do zero.

Referências

[1] Z. N. K. Swati *et al.*, "Brain tumor classification for MR images using transfer learning and fine-tuning," *Comput. Med. Imaging Graph.*, vol. 75, pp. 34–46, 2019.

[2] S. Deepak and P. M. Ameer, "Brain tumor classification using deep CNN features via transfer learning," *Comput. Biol. Med.*, vol. 111, p. 103345, 2019.

[3] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023.

[4] J. Wen *et al.*, "Convolutional neural networks for classification of Alzheimer's disease: Overview and reproducible evaluation," *Med. Image Anal.*, vol. 63, p. 101694, 2020.

[5] K. He, X. Zhang, S. Ren and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE CVPR*, 2016, pp. 770–778.

[6] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li and L. Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *Proc. IEEE CVPR*, 2009, pp. 248–255.

[7] J. Yosinski, J. Clune, Y. Bengio and H. Lipson, "How transferable are features in deep neural networks?" in *Advances in NeurIPS*, vol. 27, 2014, pp. 3320–3328.

[8] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[9] C. Nadeau and Y. Bengio, "Inference for the generalization error," *Mach. Learn.*, vol. 52, no. 3, pp. 239–281, 2003.

[10] N. Chakrabarty, "Brain MRI images for brain tumor detection," Kaggle, 2019. [Online]. Available: https://www.kaggle.com/datasets/navoneel/brain-mri-images-for-brain-tumor-detection

[11] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Proc. ICLR*, 2019.

[12] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *Proc. ICLR*, 2017.

[13] L. D. Brown, T. T. Cai and A. DasGupta, "Interval estimation for a binomial proportion," *Statist. Sci.*, vol. 16, no. 2, pp. 101–133, 2001.

[14] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman & Hall, 1993.